

AUTOMATY A GRAMATIKY

Pavel Surynek

Univerzita Karlova v Praze

Matematicko-fyzikální fakulta

Katedra teoretické informatiky a matematické logiky

8

Normální formy
bezkontextových gramatik
Pumping lemma
Zásobníkové automaty

Diagram illustrating the hierarchy of language classes:

- \mathcal{L}_0 (outermost): všechny jazyky (all languages)
- \mathcal{L}_1 : kontextové (context-sensitive)
- \mathcal{L}_2 : bezkontextové (context-free)
- \mathcal{L}_3 (innermost): regulární (regular)

Labels for the inner sets:

- regulární (regular)
- bezkontextové (context-free)
- kontextové (context-sensitive)
- rekursivně spočetné (recursively enumerable)

□ **větvící faktor** u derivačního stromu

-
- Diagram illustrating the parse tree structure for the expression $((((()))))$. The root node S branches into S and S . The left S branches into L and R , with L deriving $($. The right S branches into S and S . The rightmost S branches into L and R , with L deriving $($. An orange path highlights the derivation of the closing parenthesis $)$ from the root S node.

Převod na Chomského formu

- ke každé bezkontextové gramatice $G = (V_N, V_T, S, P)$ existuje bezkontextová gramatika $G' = (V_N', V_T, S, P')$ v Chomského normální formě, že $L(G') = L(G) - \{\lambda\}$

- **předzpracování**

- eliminace pravidel $X \rightarrow Y$ pro $X, Y \in V_N$
 - stejně jako u regulárních gramatik
- eliminace pravidel $X \rightarrow \lambda$ pro $X \in V_N$ (zde může dojít ke ztrátě λ)
 - stejně jako u převodu bezkontextové gramatiky na kontextovou

- zbývají pravidla tvaru $X \rightarrow x$ pro $X \in V_N$ a $x \in V_T$ a pravidla $X \rightarrow Y_1 Y_2 \dots Y_n$, kde $Y_i \in (V_N \cup V_T)$ pro $i = 1, 2, \dots, n$ s $n \geq 2$

- pro každý terminál $x \in V_T$ zavedeme nový neterminál X_x a pravidlo $X_x \rightarrow x$
- $X \rightarrow Y_1 Y_2 \dots Y_n$ nahradíme pravidlem $X \rightarrow Z_1 Z_2 \dots Z_n$, kde

$$Z_i = \begin{cases} Y_i & \text{když } Y_i \in V_N \\ X_{Y_i} & \text{když } Y_i \in V_T \end{cases} \quad \text{pro } i = 1, 2, \dots, n$$

- jestliže $n > 2$ vzniklé pravidlo $X \rightarrow Z_1 Z_2 \dots Z_n$ dále nahradíme pravidly
 - $X \rightarrow Z_1 B_1, B_1 \rightarrow Z_2 B_2, \dots, B_{n-2} \rightarrow Z_{n-1} Z_n$, kde B_j pro $j = 1, 2, \dots, n-2$ jsou vždy nové neterminály

Př.: $A \rightarrow BcDe$

nové neterminály

X_c, X_e

a pravidla

$X_c \rightarrow c, X_e \rightarrow e$

(i) $A \rightarrow B X_c D X_e$

(ii) $A \rightarrow B B_1$

$B_1 \rightarrow X_c B_2$

$B_2 \rightarrow D X_e$

Poznámky k převodu

- použití původního pravidla $X \rightarrow Y_1 Y_2 \dots Y_n$ je **atomické**
 - ▣ tomu musí odpovídat **atomicita** (nedělitelnost) použití sekvence náhradních pravidel
 - sekvence nových pravidel se použije buď celá nebo vůbec
 - při použití nového pravidla $X \rightarrow Z_1 B_1$ je nutno postupně použít všechna nová pravidla $B_j \rightarrow Z_{j+1} B_{j+1}$
 - jinak nelze B_j postupně přepsat neterminály
 - po použití pravidla je jednoznačně určené, které následující má být použito

Př.: bezkontextová gramatika

$G = (V_N, V_T, A, P)$, kde

$V_N = \{ A, B, C, D, E \}$

$V_T = \{ 0, 1 \}$

$P = \{ A \rightarrow B \mid C \quad B \rightarrow 0B1 \mid 01$

$C \rightarrow D \mid E \quad D \rightarrow 1D0 \mid 1$

$E \rightarrow 0E \mid 0 \}$

Př.: ekvivalentní bezkontextová v Chomského tvaru

$G' = (V_N', V_T, A, P')$, kde

$V_N' = \{ A, A_1, A_2, B, B_1, D, D_1, E, X_0, X_1 \}$

$V_T = \{ 0, 1 \}$

$P = \{ A \rightarrow X_0 A_1 \mid X_0 X_1 \mid X_1 A_2 \mid 1 \mid X_0 E \mid 0$

$A_2 \rightarrow DX_0$

$D \rightarrow X_1 D_1 \mid 1$

$B \rightarrow X_0 B_1 \mid X_0 X_1$

$D_1 \rightarrow DX_0$

$X_0 E \mid 0$

$E \rightarrow X_0 E \mid 0$

$X_0 \rightarrow 0$

$A_1 \rightarrow BX_1$

$B_1 \rightarrow BX_1$

$X_1 \rightarrow 1 \}$

Greibachové normální forma

- **Greibachové normální forma** bezkontextové gramatiky $G = (V_N, V_T, S, P)$
 - pravidla jsou tvaru $X \rightarrow xY_1Y_2...Y_n$ pro $X, Y_1, Y_2, ..., Y_n \in V_N$ a $x \in V_T$, kde $n \in \mathbb{N}_0$
 - důležité v implementaci analyzátoru
 - **předstupeň k LL(1) analyzátoru**
 - nutno ještě přidat jednoznačnost
- ke **každé bezkontextové gramatice** $G = (V_N, V_T, S, P)$ **existuje** bezkontextová gramatika $G' = (V_N'', V_T, S, P')$ v **Greibachové normální formě**, že $L(G') = L(G) - \{\lambda\}$
 - provedeme eliminaci pravidel $X \rightarrow \lambda$
 - zjednoduší se rozbor případů v dalších krocích
 - postupně
 - **odstraníme přímou levou rekurzi**, tj. pravidla tvaru $X \rightarrow Xu$ pro $X \in V_N$ a $u \in (V_N \cup V_T)^+$ nahradíme jinými
 - nahradíme **pravidla tvaru $X \rightarrow uYv$** pro $X, Y \in V_N$ a $u, v \in (V_N \cup V_T)^*$
 - u výsledné gramatiky dokončíme úpravu na Greibachovu formu

Př.: $G = (V_N, V_T, B, P)$, kde
 $V_N = \{ R, B \}$
 $V_T = \{ (,) \}$
 $P = \{ B \rightarrow (RB \quad R \rightarrow) \mid (RR \}$

Převod na Greibachově formu (1)

- **náhrada levě rekurzivních pravidel $X \rightarrow Xu$**
 - ▣ nechť $X \rightarrow Xu_1, X \rightarrow Xu_2, \dots, X \rightarrow Xu_n$ s $u_i \in (V_N \cup V_T)^+$ pro $i \in \{1, 2, \dots, n\}$ jsou všechna levě rekurzivní pravidla pro $X \in V_N$, kde
 - ▣ a $X \rightarrow v_1, X \rightarrow v_2, \dots, X \rightarrow v_k$ s $v_j \in (V_N \cup V_T)^+$ pro $j \in \{1, 2, \dots, k\}$ jsou všechna zbývající pravidla pro X
 - nahrazením všech těchto pravidel pravidly $X \rightarrow v_j Z \mid v_j$ a $Z \rightarrow u_i Z \mid u_i$ pro všechna $i=1, 2, \dots, n$ a $j=1, 2, \dots, k$ dostaneme ekvivalentní gramatiku
- **náhrada pravidel tvaru $X \rightarrow uYv$**
 - ▣ nechť $Y \rightarrow w_1, Y \rightarrow w_2, \dots, Y \rightarrow w_m$ s $w_i \in (V_N \cup V_T)^*$ pro $i \in \{1, 2, \dots, m\}$ jsou všechna pravidla pro $Y \in V_N$
 - nahrazením pravidla $X \rightarrow uYv$ pravidly $X \rightarrow uw_1v, X \rightarrow uw_2v, \dots, X \rightarrow uw_mv$ dostaneme ekvivalentní gramatiku
- chceme vytvořit gramatiku s pravidly tvaru
 - ▣ $X \rightarrow xw$, kde $X \in V_N, x \in V_T, w \in (V_N \cup V_T)^*$ nebo
 - ▣ $X \rightarrow Yw$, kde $X, Y \in V_N, w \in (V_N \cup V_T)^*$ a platí, že
 - X předchází Y v nějakém očíslování neterminálů, kde S je první




Převod na Greibachové formu (2)

- očíslovíme neterminály
 - ▣ $V_N = \{S = X_1, X_2, \dots, X_n\}$
- postupně zpracujeme pravidla pro neterminály X_1, X_2, \dots, X_n
 - ▣ když zpracovávané pravidlo je tvaru $X_i \rightarrow X_i u$ pro $u \in (V_N \cup V_T)^*$
 - provedeme nahrazení levé rekurze
 - ▣ když zpracovávané pravidlo je tvaru $X_i \rightarrow X_j u$ pro $u \in (V_N \cup V_T)^*$, kde $j < i$
 - provedeme s $X_i \rightarrow X_j u$ náhradu pravidla tvaru $X \rightarrow uYv$
 - pravidla pro X_j již byla zpracována, na začátku pravé strany se nemůže objevit neterminál s vyšším pořadovým číslem
- finální úprava na Greibachové formu
 - ▣ postupně zpracujeme pravidla pro neterminály X_n, X_{n-1}, \dots, X_1
 - pomocné neterminály z náhrad nikdy nestojí na začátku pravé strany
 - pravidla k dalšímu ošetření jsou tedy tvaru $X_i \rightarrow X_j u$ s $u \in (V_N \cup V_T)^*$ a $i < j$
 - provedeme s $X_i \rightarrow X_j u$ náhradu pravidla tvaru $X \rightarrow uYv$
 - pravidla pro X_j již byla zpracována a pravá strana pravidel pro X_n začínala terminály, na začátku pravé strany se tedy objeví terminál (indukce)
 - ▣ obdržíme pravidla tvaru $X \rightarrow xY_1Y_2\dots Y_n$ pro $X \in V_N$, $Y_1, Y_2, \dots, Y_n \in (V_N \cup V_T)$ a $x \in V_T$, kde $n \in \mathbb{N}_0$
 - stačí terminály uvnitř pravých stran nahradit novými neterminály a přidat pravidla


(bezkontextové) pumping lemma

- vezmeme-li dostatečně dlouhé slovo z jazyka lze v něm tandemově na dvou místech pumpovat
 - ▣ je-li L bezkontextový jazyk nad abecedou X , pak existují $n, m \in \mathbb{N}$, že

$$(\forall z \in L) [|z| \geq n \Rightarrow (\exists u, v, w, x, y \in X^*) (\begin{array}{l} z = u.v.w.x.y \quad \wedge \\ |vwx| \leq m \quad \wedge \\ vx \neq \lambda \quad \wedge \\ (\forall i \in \mathbb{N}_0) uv^iwx^iy \in L)] \end{array}$$
 - ▣ důkaz je založen na opakování neterminálu X na cestě z kořene do listu v **derivačním stromu**
 - pokud taková cesta a neterminál existují:



Důkaz pumping lemmatu



□ L bezkontextový, pak existují $n, m \in \mathbb{N}$

□ $(\forall z \in L) [|z| \geq n \Rightarrow (\exists u, v, w, x, y \in X^*) (z = u.v.w.x.y \wedge |vwx| \leq m \wedge vx \neq \lambda \wedge (\forall i \in \mathbb{N}_0) uv^iwx^iy \in L)]$

□ necht' $G = (V_N, V_T, S, P)$ je bezkontextová gramatika v Chomského normální formě, že $L(G) = L - \{\lambda\}$

■ větvicí faktor je nejvýše 2

■ $h = |V_N|$, $n = 2^{h-1} + 1$, $m = 2^h$

■ zvolme slovo $z \in L$, že $|z| \geq 2^{h-1} + 1$

■ každý derivační strom vzhledem ke G přinášející z obsahuje cestu z kořene do listu s délky aspoň $h+2$ (poslední je terminál, tedy aspoň $h+1$ neterminálů)

■ nějaký neterminál se na této cestě opakuje, necht' je to $X \in V_N$

■ necht' X^1 a X^2 jsou jeho dva různé výskyty nejbližší listu s

■ délka cesty z X^1 do listu s je nejvýše $h+2$, tedy $|vwx| \leq 2^h = m$

■ X^1 má dva následníky, aspoň z jednoho vede cesta do listů v rámci y nebo x

■ navíc pravidla tvaru $X \rightarrow \lambda$ nemáme, tedy $vx \neq \lambda$

■ $S \Rightarrow_G^* uX^1y \Rightarrow_G^* uvX^2xy \Rightarrow_G^* uvwxy$, pak také

■ $S \Rightarrow_G^* uX^1y \Rightarrow_G^* uvX^1xy \Rightarrow_G^* uvvX^2xxy \Rightarrow_G^* uvvwxy$

■ $S \Rightarrow_G^* uX^1y \Rightarrow_G^* uwy$

Ukázky použití pumping lemmatu

□ **L bezkontextový**, pak existují $n, m \in \mathbb{N}$

□ $(\forall z \in L)[|z| \geq n \Rightarrow (\exists u, v, w, x, y \in X^*)(z = u.v.w.x.y \wedge |vwx| \leq m \wedge vx \neq \lambda \wedge (\forall i \in \mathbb{N}_0) uv^i wx^i y \in L)]$

■ platí-li **negace** výroku **pro každé $n, m \in \mathbb{N}$** , tj. pro každé $n, m \in \mathbb{N}$ $(\exists z \in L)[|z| \geq n \wedge (\forall u, v, w, x, y \in X^*)(z = u.v.w.x.y \wedge |vwx| \leq m \wedge vx \neq \lambda \Rightarrow (\exists i \in \mathbb{N}_0) uv^i wx^i y \notin L)]$, **jazyk není bezkontextový**

□ $L_1 = \{a^i b^i c^i \mid i = 0, 1, 2, \dots\}$

■ $n, m \in \mathbb{N}$ od nepřítele

■ $k = \max(n, m)$, zvolíme $z = a^k b^k c^k$, evidentně $|z| \geq n$

■ zkoumejme všechny možné rozklady $z = u.v.w.x.y$, kde $|vwx| \leq m \wedge vx \neq \lambda$

■ **vwx nemůže obsahovat \underline{a} a \underline{c} zároveň**


■ při pumpování **nedojde k přidání \underline{a} a \underline{c} zároveň**

□ $L_2 = \{a^i b^j c^k \mid i, j, k = 0, 1, 2, \dots \wedge i \leq j \leq k\}$

■ $n, m \in \mathbb{N}$ od nepřítele, opět $k = \max(n, m)$, zvolíme $z = a^k b^k c^k$, evidentně $|z| \geq n$

■ rozklad $z = u.v.w.x.y$ nemůže v části **vwx obsahovat \underline{a} a \underline{c} zároveň**

■ při pumpování buď **přidáváme \underline{a}** , nebo **ubíráme \underline{c}** (\underline{b} lze přidávat i ubírat)



Zásobníkový automat (ZA)

□ zásobníkový automat (*push-down automaton*)


□ $Z = (Q, X, Y, \delta, q_0, z_0, F)$

- Q - konečná neprázdná množina stavů
- X - konečná neprázdná **vstupní** abeceda
- Y - konečná neprázdná **zásobníková** abeceda
- $\delta: Q \times (X \cup \{\lambda\}) \times Y \rightarrow 2_{\text{FIN}}^{Q \times Y^*}$
 - přechodová funkce trojici **stavu, čtenému symbolu pásky** (případně **nečtení**) a **čtenému symbolu ze zásobníku** přiřazuje **konečnou množinu dvojic stav a zásobníkové slovo**
 - $Q \times Y^*$ je nekonečná; nelze tedy použít $2^{Q \times Y^*}$, protože by nešlo konečně reprezentovat
- $q_0 \in Q$ - počáteční stav
- $z_0 \in Y$ - počáteční zásobníkový symbol
 - přechodová funkce **vždy ze zásobníku čte**, tj. provede operaci **pop**
 - **na začátku zásobník obsahuje z_0**
- $F \subseteq Q$ – množina přijímajících stavů

□ vyprázdnění zásobníku ukončí výpočet

□ deterministický zásobníkový automat


- $|\delta(q, x, y)| \leq 1$ pro $q \in Q, x \in X \cup \{\lambda\}$ a $y \in Y$
- když $\delta(q, \lambda, y) \neq \emptyset$ pro $q \in Q$ a $y \in Y$, pak $\delta(q, x, y) = \emptyset$ pro všechna $x \in X$



Výpočet zásobníkového automatu

u ZA hovoříme o instrukcích

- instrukce $(p, x, y) \rightarrow (q, w)$ odpovídá $(q, w) \in \delta(p, x, y)$ pro $p, q \in Q$, $x \in X$, $y \in Y$, $w \in Y^*$
 - je **použitelná**, když
 - stav řídicí jednotky je p , na pásce je čten symbol x , na vrcholu zásobníku se nachází symbol y
 - jejím **použitím** dojde ke
 - změně stavu řídicí jednotky na q , čtení pokračuje na následující buňce
 - ze zásobníku je odebrán symbol y (**pop(y)**) a na zásobník je vloženo slovo w
 - pro $w = y_1 y_2 \dots y_n$ vložení w odpovídá $\text{push}(y_n), \dots, \text{push}(y_1)$
 - instrukce $(p, \lambda, y) \rightarrow (q, w)$
 - čtený symbol není kontrolován, **nedojde** k posunu čtení na další buňku



konfigurace ZA

- trojice (q, u, v) , kde $q \in Q$, $u \in X^*$ a $v \in Y^*$
 - u - část slova na pásce, kterou zbývá přečíst (včetně právě čteného symbolu)
 - v - obsah zásobníku (směrem shora)
- konfigurace $K_1 = (p, xu, yv)$ **vede přímo** na konfiguraci $K_2 = (q, u, wv)$, kde $q \in Q$, $u \in X^*$, $x \in X$, $v, w \in Y^*$ a $y \in Y$, jestliže $(q, w) \in \delta(p, x, y)$, píšeme $K_1 \vdash_Z K_2$
 - případně $K_1 = (p, xu, yv)$ vede na $K_2 = (q, xu, wv)$, jestliže $(q, w) \in \delta(p, \lambda, y)$
- K **vede** na K' ; $K \vdash_Z^* K'$ jestliže existují K_1, K_2, \dots, K_n , kde $n \in \mathbb{N}_0$, že $K \vdash_Z K_1 \vdash_Z \dots \vdash_Z K_n \vdash_Z K'$

Jazyky přijímané ZA (1)

- $Z = (Q, X, Y, \delta, q_0, z_0, F)$
 - ▣ jazyk přijímaný přijímajícím stavem $L(Z)$
 - $L(Z) = \{ w \mid w \in X^* \wedge (\exists v, f)[v \in Y^* \wedge f \in F \wedge (q_0, w, z_0) \vdash_Z^* (f, \lambda, v)] \}$
 - ▣ jazyk přijímaný prázdným zásobníkem $N(Z)$
 - $N(Z) = \{ w \mid w \in X^* \wedge (\exists q \in Q)(q_0, w, z_0) \vdash_Z^* (q, \lambda, \lambda) \}$

Př.: $L = \{0^i 1^i \mid i=0,1,2,\dots\}$, ZA Z , že $L(Z)=L$

$Z = (\{p, q, r\}, \{0, 1\}, \{a, z\}, \delta, p, z, \{r\})$, kde

$\delta(p, 0, z) = \{(p, az)\}$

$\delta(p, 0, a) = \{(p, aa)\}$

$\delta(p, 1, a) = \{(q, \lambda)\}$

$\delta(q, 1, a) = \{(q, \lambda)\}$

$\delta(p, \lambda, z) = \{(r, \lambda)\}$

$\delta(q, \lambda, z) = \{(r, \lambda)\}$

Př.: $L = \{0^i 1^i \mid i=0,1,2,\dots\}$, ZA Z , že $N(Z)=L$

$Z = (\{p, q\}, \{0, 1\}, \{a, z\}, \delta, p, z, \emptyset)$, kde

$\delta(p, 0, z) = \{(p, a)\}$

$\delta(p, 0, a) = \{(p, aa)\}$

$\delta(p, 1, a) = \{(q, \lambda)\}$

$\delta(q, 1, a) = \{(q, \lambda)\}$

$\delta(p, \lambda, z) = \{(p, \lambda)\}$

Jazyky přijímané ZA (2)

- $Z = (Q, X, Y, \delta, q_0, z_0, F)$
 - ▣ pro zásobníkový automat Z existuje zásobníkový automat Z_1 , že $L(Z) = N(Z_1)$
 - ▣ $Z_1 = (QU\{q_0', q_f\}, X, YU\{z_0'\}, \delta', q_0', z_0', \emptyset)$
 - na zásobník pomocný symbol z_0'
 - původně vyprázdnění znamenalo konec, nyní by znamenalo přijetí
 - simulujeme Z
 - v přijímajícím stavu odebereme pomocný z_0'
 - z_0', q_0', q_f jsou nové
 - $\delta'(q_0', \lambda, z_0') = \{(q_0, z_0'z_0)\}$
 - $\delta'(q, x, y) = \delta(q, x, y)$ pro všechna $q \in Q, x \in X, y \in Y$
 - $\delta'(q, \lambda, y) = \delta(q, \lambda, y)$ pro všechna $q \in Q - F, y \in Y$
 - $\delta'(q, \lambda, y) = \delta(q, \lambda, y) \cup \{(q_f, \lambda)\}$ pro $q \in F, y \in YU\{z_0'\}$
 - zde rušíme determinismus
 - $\delta'(q_f, \lambda, y) = \{(q_f, \lambda)\}$ pro $y \in YU\{z_0'\}$
 - ▣ $w \in L(Z) \Leftrightarrow (q_0, w, z_0) \vdash_Z^* (f, \lambda, v)$ pro $f \in F$ a $v \in Y^* \Leftrightarrow$
 $(q_0', w, z_0') \vdash_{Z_1} (q_0, w, z_0'z_0') \vdash_{Z_1}^* (f, \lambda, vz_0') \vdash_{Z_1} (q_f, \lambda, vz_0') \vdash_{Z_1}^* (q_f, \lambda, \lambda)$
 $\Leftrightarrow w \in N(Z_1)$

Jazyky přijímané ZA (3)

- $Z = (Q, X, Y, \delta, q_0, z_0, F)$
- ▣ pro zásobníkový automat Z existuje zásobníkový automat Z_2 , že $N(Z) = L(Z_2)$
 - navíc, když Z je deterministický, je i Z_2 deterministický
- ▣ $Z_2 = (Q \cup \{q_0', q_f\}, X, Y \cup \{z_0'\}, \delta', q_0', z_0', \{q_f\})$
 - na zásobník pomocný symbol z_0'
 - simulujeme Z
 - je-li na zásobníku vidět pomocný z_0' , přijímáme, neboť to odpovídá původnímu vyprázdnění
 - z_0', q_0', q_f jsou nové
 - $\delta'(q_0', \lambda, z_0') = \{(q_0, z_0'z_0)\}$
 - $\delta'(q, x, y) = \delta(q, x, y)$ pro všechna $q \in Q, x \in X, y \in Y$
 - $\delta'(q, \lambda, y) = \delta(q, \lambda, y)$ pro všechna $q \in Q, y \in Y$
 - $\delta'(q, \lambda, z_0') = \{(q_f, \lambda)\}$ pro všechna $q \in Q$
- ▣ $w \in N(Z) \Leftrightarrow (q_0, w, z_0) \vdash_Z^* (q, \lambda, \lambda)$ pro $q \in Q \Leftrightarrow$
 $(q_0', w, z_0') \vdash_{Z_2} (q_0, w, z_0'z_0') \vdash_{Z_2}^* (q, \lambda, z_0') \vdash_{Z_2} (q_f, \lambda, \lambda)$
 $\Leftrightarrow w \in L(Z_2)$