

AUTOMATY A GRAMATIKY

Pavel Surynek

Univerzita Karlova v Praze

Matematicko-fyzikální fakulta

Katedra teoretické informatiky a matematické logiky

10

Pokročilé uzávěrové vlastnosti

Rozhodovací problémy

Determinismus u ZA

Uzávěrové vlastnosti u DZA

Kontextové jazyky

Pokročilé uzávěrové vlastnosti (1)

- bezkontextové jazyky jsou uzavřené na **inverzní homomorfismus**
 - homomorfismus je **speciální případ bezkontextové (regulární substituce)**
 - substituce $f: X \rightarrow 2^{\Sigma^*}$ je **homomorfismus**, jestliže $|f(x)|=1$ pro každé $x \in X$
 - $f: X \rightarrow 2^{\Sigma^*}$ homomorfismus, L, K bezkontextové jazyky nad X , resp. nad Σ
 - $f(L) = \{w_1 w_2 \dots w_n \mid (\exists x_1 x_2 \dots x_n \in L) w_1 \in f(x_1) \wedge w_2 \in f(x_2) \wedge \dots \wedge w_n \in f(x_n)\}$
 - **víme, že $f(L)$ je bezkontextový**
 - $f^{-1}(K) = \{x_1 x_2 \dots x_n \mid (\exists w_1 w_2 \dots w_n \in K) w_1 \in f(x_1) \wedge w_2 \in f(x_2) \wedge \dots \wedge w_n \in f(x_n)\}$
 - **$f^{-1}(K)$ je bezkontextový**
 - existuje **$ZA Z = (Q, \Sigma, Y, \delta, q_0, z_0, F)$, že $L(Z) = K$**
 - definujeme **$ZA Z' = (Q', X, Y, \delta', [q_0, \lambda], z_0, F \times \{\lambda\})$** , kde
 - $Q' = \{[q, u] \mid q \in Q \wedge u \in \Sigma^* \wedge (\exists x \in X, \exists v \in \Sigma^*) f(x) = vu\}$
 - použitých slov u, v je **konečně mnoho**
 - $\delta'([q, u], \lambda, y) = \begin{aligned} &\{([p, u], w) \mid (p, w) \in \delta(q, \lambda, y)\} \\ &\cup \{([p, v], w) \mid (p, w) \in \delta(q, \sigma, y) \wedge u = \sigma v\} \end{aligned}$
 - $\delta'([q, \lambda], x, y) = \{[q, f(x)], y\}$
 - po přečtení **páskového symbolu x je do druhé komponenty stavu vloženo $f(x)$**
 - **nad druhou komponentou stavu proběhne simulace Z , přičemž pásku nečteme**
 - platí, že **$L(Z') = f^{-1}(L(Z)) = f^{-1}(K)$**

Pokročilé uzávěrové vlastnosti (2)

- bezkontextové jazyky jsou uzavřené na průnik s regulárním jazykem
 - ▣ paralelně simulujeme zásobníkový a konečný automat
 - R regulární jazyk, že $R = L(A)$ pro konečný automat $A = (Q_A, X, \delta_A, q_{A0}, F_A)$
 - L bezkontextový jazyk, že $L = L(Z)$ pro zásobníkový automat $Z = (Q_Z, X, Y, \delta_Z, q_{Z0}, z_0, F_Z)$
 - ▣ definujeme zásobníkový automat $Z' = (Q_A \times Q_Z, X, Y, \delta, [q_{A0}, q_{Z0}], z_0, F_A \times F_Z)$, kde
 - $\delta([p, q], x, y) \ni ([r, s], u)$, jestliže
 - $p=r$ a $(s, u) \in \delta_Z(q, x, y)$ pro $x = \lambda$
 - Z nečte pásku, pracuje na zásobníku, A nepracuje
 - $r = \delta_A(p, x)$ a $(s, u) \in \delta_Z(q, x, y)$ pro $x \neq \lambda$
 - Z a A současně zpracují symbol x
 - $L(Z') = L(A) \cap L(Z) = R \cap L$

Pokročilé uzávěrové vlastnosti (3)

- bezkontextové jazyky jsou uzavřené na kvocienty s regulárním jazykem
 - pro levý kvocient paralelně simulujeme konečný a zásobníkový automat, jakmile se KA dostane do přijímajícího stavu, ZA začne zpracovávat vstup
 - R regulární jazyk, že $R = L(A)$ pro konečný automat $A = (Q_A, X, \delta_A, q_{A0}, F_A)$
 - L bezkontextový jazyk, že $L = L(Z)$ pro zásobníkový automat $Z = (Q_Z, X, Y, \delta_Z, q_{Z0}, z_0, F_Z)$
 - připomenutí
 - $R \setminus L = \{ v \mid (\exists u \in R) uv \in L \}$
 - $L / R = \{ u \mid (\exists v \in R) uv \in L \}$
 - definujeme zásobníkový automat $Z' = (Q_A \times Q_Z \cup Q_Z, X, Y, \delta, [q_{A0}, q_{Z0}], z_0, F_Z)$, kde
 - $\delta([p, q], \lambda, y) = \begin{aligned} &\{([r, s], u) \mid (\exists x \in X)(r = \delta_A(p, x) \wedge (s, u) \in \delta_Z(q, x, y))\} \\ &\cup \{([p, s], u) \mid (s, u) \in \delta_Z(q, \lambda, y)\} \\ &\cup \{(q, y) \mid p \in F_A\} \end{aligned}$
 - $\delta(q, x, y) = \delta_Z(q, x, y)$ pro $x \in X \cup \{\lambda\}, q \in Q_Z$
 - $L(Z') = L(A) \setminus L(Z) = R \setminus L$

Rozhodovací problémy

- dán bezkontextový jazyk L nad X a slovo $w \in X^*$, chceme **testovat**, zda $w \in L$
 - předpokládejme, že máme gramatiku $G = (V_N, V_T, S, P)$ v **Chomského normálním tvaru**, že $L(G) = L$ a $w = x_1 x_2 \dots x_n$
- **algoritmus CYK**
 - najdeme $X_{i,j}$ pro $i, j = 1, 2, \dots, n$, kde
 - $X_{i,j} = \{ X \mid X \in V_N \wedge X \Rightarrow_G^* x_i x_{i+1} \dots x_j \}$
 - když $S \in X_{1,n}$, máme $S \Rightarrow_G^* w$ a tedy $w \in L$
 - dynamické programování
 - $X_{i,i} = \{ X \mid X \in V_N \wedge X \Rightarrow_G X_i \}$
 - jeden odvozovací krok stačí díky Chomského tvaru
 - $X_{i,j} = \{ X \mid (\exists k \in \{i, i+1, \dots, j-1\}) [(\exists Y \in X_{i,k}) (\exists Z \in X_{k+1,j}) X \Rightarrow_G YZ] \}$
 - čas $O(|w|^3)$
- test, zda **L je nekonečný**
 - pomocí pumping lemmatu
 - existuje slovo $w \in L$, že $|w| \geq n$ a $|w| \leq 2n-1$
- test, zda $L = \emptyset$
 - regularizací

Př.: $G = (V_N, V_T, S, P)$, kde
 $V_N = \{ S, A, B, C \}$
 $V_T = \{ a, b, c \}$
 $P = \{ S \rightarrow AB \mid BC$
 $A \rightarrow BA \mid a$
 $B \rightarrow CC \mid b$
 $C \rightarrow AB \mid a \}$
 $w = baaba$

$X_{i,j}$	j				
i	B	S,A	\emptyset	\emptyset	S,A,C
	\emptyset	A,C	B	B	S,A,C
	\emptyset	\emptyset	A,C	S,C	B
	\emptyset	\emptyset	\emptyset	B	S,A
	\emptyset	\emptyset	\emptyset	\emptyset	A,C

Determinismus u ZA (1)

- **zásobníkový automat** $Z = (Q, X, Y, \delta, q_0, z_0, F)$ je **deterministický** (DZA), jestliže
 - $|\delta(q, x, y)| \leq 1$ pro všechna $q \in Q, x \in X \cup \{\lambda\}, y \in Y$
 - když $\delta(q, \lambda, y) \neq \emptyset$ pro $q \in Q$ a $y \in Y$, pak $\delta(q, x, y) = \emptyset$ pro všechna $x \in X$
- jazyk L je **deterministický bezkontextový**, jestliže **existuje deterministický ZA** Z , že $L = L(Z)$
 - $K = \{ww^R \mid w \in \{a,b\}^*\}$ je bezkontextový, ale **nikoli deterministický**
 - je třeba **nedeterministicky uhádnout střed** vstupního slova
- jazyk L se nazývá **bezprefixový**, jestliže **pro každé** $u, v \in L$ platí
 - když u je prefix v , pak $u = v$


Determinismus u ZA (2)

- necht' Z je deterministický zásobníkový automat, pak říkáme, že $N(Z)$ je **bezkontextový bezprefixový jazyk**
 - ▣ pro $w \in X^*$ $w \in N(Z) \Rightarrow (\forall v \in X^*)(v \neq \lambda \Rightarrow wv \notin N(Z))$
 - po přechzení w je zásobník vyprázdněn a není možné pokračovat
 - ▣ jelikož konstrukce Z' , že $L(Z') = N(Z)$ zachovává determinismus, je $N(Z)$ rovněž deterministický bezkontextový jazyk
- nikoli každý deterministický bezkontextový jazyk je bezprefixový
 - ▣ uvažme regulární $L = \{a, aa\}$
- když L nad abecedou X je deterministický bezkontextový jazyk, pak $L.\$$ pro $\$ \notin X$ je bezkontextový bezprefixový

Zjemnění Chomského hierarchie

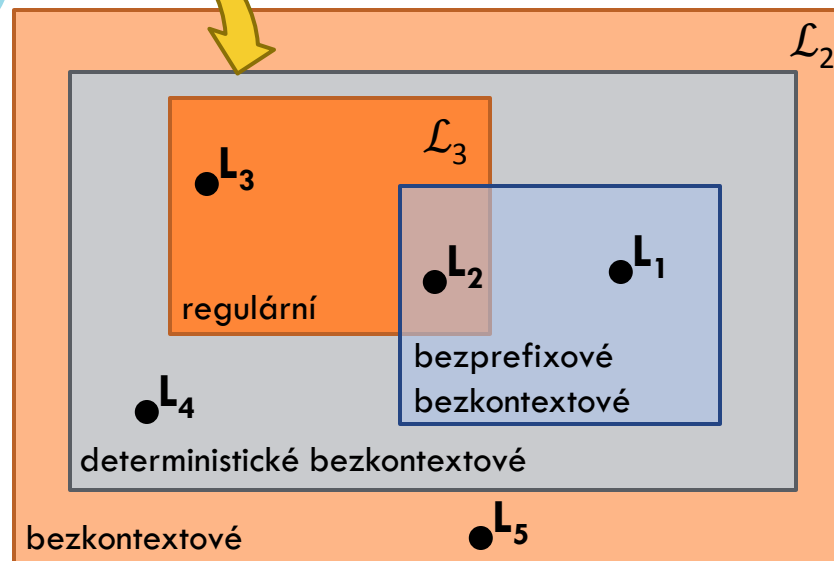
□ svědci

- $L_1 = \{a^i b^i \mid i=1,2,\dots\}$
- $L_2 = \{aba\}$
- $L_3 = \{a, aa\}$



□ další svědci

- $L_4 = \{a^i b^j \mid i,j=1,2,\dots \wedge i \leq j\}$
- $L_5 = \{ww^R \mid w \in \{a,b\}^*\}$




Uzávěrové vlastnosti pro DZA (1)

- deterministické bezkontextové jazyky jsou uzavřené na **doplňk**
 - ▣ připomeňme: bezkontextové na doplňk uzavřené nejsou
- důkaz je technicky náročný, uvedeme jen několik myšlenek
 - ▣ případy nepřijetí stavem u deterministického ZA
 - (i) přečte vstupní slovo a skončí v nepřijímajícím stavu
 - (ii) vyprázdní zásobník
 - (iii) dostane se do konfigurace, která nemá pokračování
 - (iv) zacyklí se v krocích na zásobníku
 - opakují se konfigurace
 - (v) dojde k nekontrolovatelnému růstu zásobníku
 - ▣ případy (i), (ii), (iii) lze poznat snadno, případy (iv) a (v) obtížněji

Uzávěrové vlastnosti pro DZA (2)

- deterministické bezkontextové jazyky jsou uzavřené na **inverzní homomorfismus** a **průnik s regulárním jazykem**
 - předchozí konstrukce zachovají determinismus
- deterministické bezkontextové jazyky nejsou uzavřené na **průnik, sjednocení a homomorfismus**
 - důkaz pro sjednocení
 - $L = \{a^i b^j c^k \mid i, j, k = 0, 1, 2, \dots \wedge (i \neq j \vee j \neq k \vee i \neq k)\}$ je bezkontextový (sjednocení tří deterministických)
 - necht' L je navíc deterministický, pak $\neg L$ rovněž
 - $K = \{a^i b^j c^k \mid i, j, k = 0, 1, 2, \dots\}$ je regulární a $(\neg L) \cap K = \{a^i b^i c^i \mid i = 0, 1, 2, \dots\}$, který není bezkontextový
 - důkaz pro homomorfismus
 - $L = \{a^i b^j c^j \mid i, j = 0, 1, 2, \dots\}$
 - $K = \{a^i b^j c^j \mid i, j = 0, 1, 2, \dots\}$
 - K a L jsou deterministické bezkontextové
 - $0L \cup 1K$ je deterministický bezkontextový, $1L \cup 1K$ nikoli
 - nedeterminismus $1L \cup 1K$ rozborem případů
 - $f(0) = 1$, identita jinak, pak $f(0L \cup 1K) = 1L \cup 1K$

Kontextové jazyky (1)



kontextové jazyky

generované **kontextovými** gramatikami (context sensitive) [typu 1]

- pravidla tvaru $\alpha X \beta \rightarrow \alpha w \beta$, kde $\alpha, \beta \in (V_N \cup V_T)^*$, $X \in V_N$ a $w \in (V_N \cup V_T)^*$ a $w \neq \lambda$
- nebo $S \rightarrow \lambda$, pokud S není na pravé straně žádného jiného pravidla

generované **nezkracujícími** gramatikami

- pravidla tvaru $\alpha \rightarrow \beta$, kde $\alpha, \beta \in (V_N \cup V_T)^*$ a $|\alpha| \leq |\beta|$
- nebo $S \rightarrow \lambda$, pokud S není na pravé straně žádného jiného pravidla
- kontextová pravidla jsou nezkracující, naopak nikoli

pro každou nezkracující gramatiku $G = (V_N, V_T, S, P)$ existuje kontextová gramatika $G' = (V_N', V_T, S, P')$, že $L(G) = L(G')$

ukazuje, že definice jsou **ekvivalentní**

Př.: $G = (V_N, V_T, S, P)$, kde
 $V_N = \{S, A, B, C\}$
 $V_T = \{a, b, c\}$
 $P = \{$
 $S \rightarrow aSBC \mid abc$
 $CB \rightarrow BC$
 $bB \rightarrow bb$
 $bC \rightarrow bc$
 $cC \rightarrow cc$
 $\}$

G je nezkracující,
ale nikoli kontextová

$L(G) = \{a^i b^i c^i \mid i = 1, 2, \dots\}$

Kontextové jazyky (2)

□ $G = (V_N, V_T, S, P)$ nezkracující gramatika

▣ nejprve **separace**

- výsledkem je separovaná gramatika $G'' = (V_N'', V_T, S, P'')$
 - pro každý terminál $x \in V_T$ zavedeme nový neterminál X_x
 - v pravidlech nahradíme každý terminál x za X_x
 - zavedeme pravidla $X_x \rightarrow x$
- $L(G'') = L(G)$

▣ **náhrada nezkracujícího** pravidla $\alpha \rightarrow \beta$ sérií kontextových

- necht' $\alpha \rightarrow \beta = A_1 A_2 \dots A_m \rightarrow B_1 B_2 \dots B_n$, kde $m \leq n$
 - $A_1 A_2 \dots A_m \rightarrow C_1 A_2 \dots A_m$
 - $C_1 A_2 \dots A_m \rightarrow C_1 C_2 \dots A_m \quad \dots$
 - $C_1 \dots C_{m-1} A_m \rightarrow C_1 C_2 \dots C_m$
 - $C_1 C_2 \dots C_m \rightarrow B_1 C_2 \dots C_m$
 - $B_1 C_2 C_2 \dots C_m \rightarrow B_1 B_2 C_3 \dots C_m \quad \dots$
 - $B_1 B_2 \dots B_{m-1} C_m \rightarrow B_1 B_2 \dots B_{m-1} B_m B_{m+1} \dots B_n$
- C_1, C_2, \dots, C_m jsou pro každé nahrazované pravidlo nové

Př.: $AB \rightarrow BA$

zavedeme
neterminály C_1, C_2

náhrada za $AB \rightarrow BA$

$AB \rightarrow C_1 B$

$C_1 B \rightarrow C_1 C_2$

$C_1 C_2 \rightarrow B C_2$

$B C_2 \rightarrow BA$

Kontextové uzávěrové vlastnosti (1)

- kontextové jazyky jsou uzavřené na konečná **sjednocení**
 - kontextové gramatiky $G_1=(V_N^1, V_T, S_1, P_1)$ a $G_2=(V_N^2, V_T, S_2, P_2)$, kde $V_N^1 \cap V_N^2 = \emptyset$
 - položme $G = (V_N^1 \cup V_N^2 \cup \{S'\}, V_T, S', P_1 \cup P_2 \cup \{S' \rightarrow S_1 | S_2\})$
 - S' je nový neterminál
 - ošetřit přepis původních počátečních symbolů na λ
 - platí $L(G) = L(G_1) \cup L(G_2)$
- kontextové jazyky jsou uzavřené na **konkatenaci**
 - položme $G = (V_N^1 \cup V_N^2 \cup \{S'\}, V_T, S', P_1 \cup P_2 \cup \{S' \rightarrow S_1.S_2\})$
 - S' je nový neterminál
 - ošetřit přepis původních počátečních symbolů na λ
 - platí $L(G) = L(G_1).L(G_2)$
- kontextové jazyky jsou uzavřené na **iteraci**
 - položme $G = (V_N^1 \cup \{S', S''\}, V_T, S', P_1 \cup \{S' \rightarrow \lambda | S'', S'' \rightarrow S''S_1 | S_1\})$
 - S', S'' jsou nové neterminály
 - je třeba dávat pozor na výskyt počátečního neterminálu vpravo (u bezkontextových netřeba)
 - platí $L(G) = L(G_1)^*$
- kontextové jazyky jsou uzavřené na **zrcadlový obraz**
 - položme $G = (V_N^1, V_T, S_1, \{v^R \rightarrow w^R | v \rightarrow w \in P_1\})$
 - platí $L(G) = L(G_1)^R$

Kontextové uzávěrové vlastnosti (2)

- kontextové jazyky jsou uzavřené na **kontextovou substituci**
 - ▣ substituce $f: X \rightarrow 2^{Y^*}$ je kontextová substituce, jestliže $f(x)$ je kontextový jazyk pro každé $x \in X$
 - máme $G_x = (V_N^x, Y, S_x, P_x)$, že $f(x) = L(G_x)$ pro každé $x \in X$
 - V_N^x jsou po dvou disjunktní
 - ▣ mějme $G = (V_N, X, S, P)$, zajímá nás kontextovost $f(L(G))$
 - ▣ položíme $G' = (V_N \cup \bigcup_{x \in X} V_N^x \cup X, Y, S, P \cup \bigcup_{x \in X} P^x \cup \{x \rightarrow S_x \mid x \in X\})$
 - případně ošetříme přepis neterminálů jiných než S na λ
 - platí $L(G') = f(L(G))$
- kontextové jazyky jsou **uzavřené na doplňky a konečné průniky**
 - ▣ velmi hluboký výsledek (řešilo se asi 20 let)
 - věta Immerman–Szelepcsényi