

# Monte-Carlo metody

**© 1996-2016 Josef Pelikán**  
**CGG MFF UK Praha**

[pepca@cgg.mff.cuni.cz](mailto:pepca@cgg.mff.cuni.cz)

<http://cgg.mff.cuni.cz/~pepca/>



# Monte Carlo integrace

**Odhadovaný integrál:**

$$I = \int_0^1 f(x) dx$$

Předpoklad:  $f(x) \in L^2(0,1)$


Je-li  $\xi$  náhodné číslo s distribucí  $R(0,1)$ , pak  $f(\xi)$  je tzv. **primární odhad** integrálu:

$$\underline{\langle I \rangle_{\text{prim}} = f(\xi)}$$

Odhad je **nestranný**, neboť:

$$\underline{E(\langle I \rangle_{\text{prim}}) = \int_0^1 f(x) dx = I}$$

# Primární odhad určitého integrálu





# Rozptyl odhadu




Měřítkem kvality odhadu je jeho **rozptyl** (nebo standardní odchylka):

$$\underline{V\left(\langle I \rangle_{\text{prim}}\right) = \sigma_{\text{prim}}^2 = \int_0^1 |f(\mathbf{x}) - I|^2 d\mathbf{x} = \int_0^1 f(\mathbf{x})^2 d\mathbf{x} - I^2}$$

(pro nestranný odhad)

Při výpočtu **jediného vzorku** je rozptyl výsledku příliš velký!

# Sekundární odhad integrálu





# Sekundární odhad

Rozložení integrálu na součet **N členů**:

$$I = \int_0^1 f(\mathbf{x}) \, d\mathbf{x} = \sum_{i=1}^N \int_0^1 \frac{f(\mathbf{x})}{N} \, d\mathbf{x} = \sum_{i=1}^N I_i$$

**Sekundární odhad** integrálu:

$$\underline{\langle I \rangle_{\text{sec}}} = \sum_{i=1}^N \langle I_i \rangle_{\text{prim}} = \underline{\frac{1}{N} \sum_{i=1}^N f(\xi_i)}$$

Sekundární odhad je také **nestranný**.



# Rozptyl sekundárního odhadu

$$\begin{aligned}\underline{\sigma_{\text{sec}}^2} &= \int_0^1 \cdots \int_0^1 \left[ \frac{1}{N} \sum_{i=1}^N f(\mathbf{x}_i) \right]^2 d\mathbf{x}_1 \cdots d\mathbf{x}_N - I^2 = \\ &= \frac{1}{N} \int_0^1 f^2(\mathbf{x}) d\mathbf{x} - \frac{1}{N} I^2 = \\ &= \underline{\frac{\sigma_{\text{prim}}^2}{N}} \quad \dots \text{std. chyba je } \sqrt{N}\text{-krát menší!} \\ &\quad \text{(konvergence } 1/\sqrt{N}\text{)}\end{aligned}$$




# Vzorkování po částech

- ♦ při výběru množiny nezávislých vzorků se stejnou hustotou pravděpodobnosti dochází ke **shlukování**
  - zbytečně velký rozptyl odhadu
- ➔ **vzorkování po částech** (“stratified sampling”)
  - potlačuje shlukování
  - redukuje rozptyl odhadu
- ➔ interval se rozdělí na části, které se odhadují **samostatně**



# Vzorkování po částech





# Vzorkování po částech

Rozdělení intervalu  $(0,1)$  na  $N$  částí  $A_i$ :

$$I = \int_0^1 f(\mathbf{x}) \, d\mathbf{x} = \sum_{i=1}^N \int_{A_i} f(\mathbf{x}) \, d\mathbf{x} = \sum_{i=1}^N I_i$$

Odhad integrálu:

$$\langle I \rangle_{\text{strat}} = \sum_{i=1}^N \langle I_i \rangle_{\text{prim}} = \frac{1}{N} \sum_{i=1}^N f(\xi_i), \quad f(\xi_i) \in A_i$$



# Rozptyl vzorkování po částech

$$\begin{aligned}\sigma_{\text{strat}}^2 &= \sum_{i=1}^N \left[ \int_{A_i} \left[ \frac{f(\mathbf{x}_i)}{N} \right]^2 N d\mathbf{x}_i - I_i^2 \right] = \\ &= \frac{1}{N} \int_0^1 f^2(\mathbf{x}) d\mathbf{x} - \sum_{i=1}^N I_i^2 \leq \sigma_{\text{sec}}^2\end{aligned}$$

... rozptyl nemůže být větší než  
u **sekundárního odhadu!**



# Rozklad intervalu na části


- ♦ **uniformní** rozklad intervalu  $(0,1)$ 
  - přirozená metoda pro zcela neznámou funkci **f**
- ♦ známe-li alespoň přibližně **průběh funkce f**, snažíme se o takový rozklad, aby byl rozptyl funkce na subintervalech co nejmenší
- ♦ rozklad **d-rozměrného intervalu** vede na  $N^d$  výpočtů
  - úspornější metodou je vzorkování “**N věží**”



# Vzorkování podle důležitosti

- ♦ některé části vzorkovaného intervalu jsou **důležitější**, protože zde má  **$f$**  větší hodnotu
  - vzorky z těchto oblastí mají větší vliv na výsledek
- ➔ **vzorkování podle důležitosti** (“importance sampling”) umisťuje vzorky přednostně do takových oblastí
  - vzorkování je formálně řízeno funkcí  **$p(\mathbf{x})$**  ... **hustotou pravděpodobnosti** na daném intervalu
- ➔ **menší rozptyl** při zachování nestrannosti

# Vzorkování podle důležitosti





# Vzorkování podle důležitosti

Úprava odhadovaného integrálu:

$$I = \int_0^1 f(\mathbf{x}) \, d\mathbf{x} = \int_0^1 \frac{f(\mathbf{x})}{p(\mathbf{x})} p(\mathbf{x}) \, d\mathbf{x}$$

Má-li náhodná proměnná  $\xi$  rozdělení s hustotou  $p(\mathbf{x})$ , odhadujeme integrál  $I$  výrazem:

$$\langle I \rangle_{\text{imp}} = \frac{f(\xi)}{p(\xi)} \quad (\text{tento odhad je } \mathbf{nestranný})$$

# Rozptyl vzorkování podle důležitosti

$$\begin{aligned}\underline{\sigma_{\text{imp}}^2} &= \int_0^1 \left[ \frac{f(\mathbf{x})}{p(\mathbf{x})} \right]^2 p(\mathbf{x}) d\mathbf{x} - I^2 = \\ &= \underline{\int_0^1 \frac{f^2(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x} - I^2}\end{aligned}$$

Pokud se průběh hustoty  $p(\mathbf{x})$  podobá integrované funkci  $f(\mathbf{x})$ , odhadujeme integrál funkce, která má **menší rozptyl** než  $f(\mathbf{x})$ .





# Vlastnosti hustoty $p(x)$

- ♦  $p(x) \geq 0$  a  $p(x) > 0$  tam, kde  $f(x) \neq 0$
- ♦  $\int p(x) dx = 1$
- ♦ lze **efektivně generovat** vzorky s danou hustotou pravděpodobnosti
  - lze spočítat příslušnou **distribuční funkci  $P(x)$**  a zinvertovat ji ( $P^{-1}(x)$ )

$$\underline{P(x)} = \int_0^x p(t) dt$$



# Praktická implementace

Místo přímého výběru náhodné proměnné s hustotou pravděpodobnosti  $\mathbf{p}(\mathbf{x})$  bereme  $\tau$  s **rovnoměrným rozdělením** pravděpodobnosti a transformujeme ji:


$$\underline{\xi = \mathbf{P}^{-1}(\tau)}$$

Odhad má tedy tvar:

$$\langle \mathbf{I} \rangle_{\text{imp}} = \frac{\mathbf{f}(\mathbf{P}^{-1}(\tau))}{\mathbf{p}(\mathbf{P}^{-1}(\tau))}$$

$$\mathbf{I} = \int_0^1 \mathbf{f}(\mathbf{x}) \, d\mathbf{x} = \int_0^1 \mathbf{f}(\mathbf{P}^{-1}(\mathbf{t})) \frac{d\mathbf{P}^{-1}(\mathbf{t})}{d\mathbf{t}} \, d\mathbf{t} = \int_0^1 \frac{\mathbf{f}(\mathbf{P}^{-1}(\mathbf{t}))}{\mathbf{p}(\mathbf{P}^{-1}(\mathbf{t}))} \, d\mathbf{t}$$

# Kombinované odhady





# Kombinace několika odhadů

Předpokládáme  $n$  náhodných proměnných  $\xi_1, \dots, \xi_n$  s hustotami pravděpodobnosti  $p_1(\mathbf{x}), \dots, p_n(\mathbf{x})$ .

**Kombinovaný odhad** integrálu bude mít tvar:

$$\langle I \rangle_{\text{comb}} = \sum_{i=1}^n w_i(\xi_i) \frac{f(\xi_i)}{p_i(\xi_i)}$$

kde  $w_i(\mathbf{x})$  jsou nezáporné **váhové funkce**.

# Nestrannost kombinovaného odhadu

$$\begin{aligned}\underline{E(\langle I \rangle_{\text{comb}})} &= \sum_{i=1}^n \int_0^1 \left[ w_i(\mathbf{x}_i) \frac{f(\mathbf{x}_i)}{p_i(\mathbf{x}_i)} \right] p_i(\mathbf{x}_i) d\mathbf{x}_i = \\ &= \int_0^1 \left[ \underline{\sum_{i=1}^n w_i(\mathbf{x})} \right] f(\mathbf{x}) d\mathbf{x} \equiv \underline{\int_0^1 f(\mathbf{x}) d\mathbf{x}}\end{aligned}$$

Podmínka pro  
**váhové funkce:**

$$\forall \mathbf{x}: \sum_{i=1}^n w_i(\mathbf{x}) = 1$$

# Rozptyl kombinovaného odhadu



$$\begin{aligned}\underline{\sigma_{\text{comb}}^2} &= \sum_{i=1}^n \left\{ \int_0^1 \left[ w_i(\mathbf{x}_i) \frac{f(\mathbf{x}_i)}{p_i(\mathbf{x}_i)} \right]^2 p_i(\mathbf{x}_i) d\mathbf{x}_i - \right. \\ &\quad \left. - \left[ \int_0^1 w_i(\mathbf{x}_i) \frac{f(\mathbf{x}_i)}{p_i(\mathbf{x}_i)} p_i(\mathbf{x}_i) d\mathbf{x}_i \right]^2 \right\} = \\ &= \int_0^1 \left[ \sum_{i=1}^n \frac{w_i^2(\mathbf{x})}{p_i(\mathbf{x})} \right] f(\mathbf{x}) d\mathbf{x} - \sum_{i=1}^n \left[ \int_0^1 w_i(\mathbf{x}) f(\mathbf{x}) d\mathbf{x} \right]^2\end{aligned}$$



# Aritmetický průměr, maximum

$$w_i(\mathbf{x}) = \frac{1}{n}$$

$$\langle I \rangle_{\text{average}} = \frac{1}{n} \sum_{i=1}^n \frac{f(\xi_i)}{p_i(\xi_i)}$$

$$w_i(\mathbf{x}) = \begin{cases} 1 & \text{pro } p_i(\mathbf{x}) = \max_j \{ p_j(\mathbf{x}) \} \\ 0 & \text{jinde} \end{cases}$$

$$\langle I \rangle_{\text{max}} = \sum_{i=1}^n \left( p_i(\xi_i) = \max_j \{ p_j(\xi_i) \} \right) ? \frac{f(\xi_i)}{p_i(\xi_i)} : 0$$



# Vyrovnaná heuristika

$$w_i(\mathbf{x}) = \frac{p_i(\mathbf{x})}{\sum_{j=1}^n p_j(\mathbf{x})}$$

$$\langle I \rangle_{\text{bal}} = \sum_{i=1}^n \frac{f(\xi_i)}{\sum_{j=1}^n p_j(\xi_i)}$$

$$\sigma_{\text{bal}}^2 = \int_0^1 \frac{f^2(\mathbf{x})}{\sum_{i=1}^n p_i(\mathbf{x})} d\mathbf{x} - \sum_{i=1}^n \left[ \int_0^1 \frac{p_i(\mathbf{x})}{\sum_{j=1}^n p_j(\mathbf{x})} f(\mathbf{x}) d\mathbf{x} \right]^2$$

$$\sigma_{\text{comb}}^2 \geq \sigma_{\text{bal}}^2 - \left(1 - \frac{1}{n}\right) \cdot I^2$$





# Mocninná heuristika

Zobecnění: 
$$\mathbf{w}_i(\mathbf{x}) = \frac{\mathbf{p}_i^\beta(\mathbf{x})}{\sum_{j=1}^n \mathbf{p}_j^\beta(\mathbf{x})}$$

$$\langle \mathbf{I} \rangle_{\text{power}} = \sum_{i=1}^n \frac{\mathbf{p}_i^{\beta-1}(\xi_i)}{\sum_{j=1}^n \mathbf{p}_j^\beta(\xi_i)} \mathbf{f}(\xi_i)$$

$\beta = 1$  .. vyrovnaná,  $\beta = \infty$  .. maximální heuristika



# Transformace integrandu

Interpretace kombinačního odhadu jako  
**transformace integrované funkce:**


$$I = \int_0^1 f(\mathbf{x}) \, d\mathbf{x} = \sum_{i=1}^n \int_0^1 w_i(\mathbf{x}) \cdot f(\mathbf{x}) \, d\mathbf{x}$$

Kombinace odhadů podle důležitosti:


$$I = \sum_{i=1}^n \int_0^1 \frac{w_i(\mathbf{P}_i^{-1}(\mathbf{t}))}{p_i(\mathbf{P}_i^{-1}(\mathbf{t}))} f(\mathbf{P}_i^{-1}(\mathbf{t})) \, d\mathbf{t}$$

---


# Jeden člen kombinovaného odhadu




# Aritmetický průměr



# Maximum




# Vyrovnaná heuristika





# Mocninná heuristika pro $\beta=2$



# Řídící funkce




Funkce  **$g(x)$** , která **aproximuje integrand** a dokážeme ji **analyticky zintegrovat**:

$$\begin{aligned} I &= \int_0^1 f(x) dx = \int_0^1 [f(x) - g(x)] dx + \underbrace{\int_0^1 g(x) dx}_{J} = \\ &= \int_0^1 [f(x) - g(x)] dx + \underline{J} = \int_0^1 [f(x) - g(x) + J] dx \end{aligned}$$

Nestranný odhad:  $\langle I \rangle_{\text{con}} = f(\xi) - g(\xi) + J$



# Transformace řídicí funkcí



# Řešení integrálních rovnic



Fredholmova integrální rovnice druhého typu:

$$\underline{f(x)} = g(x) + \int_0^1 K(x, y) \cdot \underline{f(y)} dy$$

neznámá

známé funkce

- ➡ metody **konečných prvků** (výpočet celé funkce)
- ➡ metody **Monte Carlo** (lokální výpočet)

# Rekurzivní Monte Carlo odhad



**Pravou stranu rovnice odhadují stochasticky s řídicími hustotami pravděpodobnosti  $p_i(\mathbf{x})$ :**

$$\begin{aligned}\langle \mathbf{f}(\mathbf{x}) \rangle_r &= \mathbf{g}(\mathbf{x}) + \frac{\mathbf{K}(\mathbf{x}, \xi_1)}{p_1(\xi_1)} \cdot \langle \mathbf{f}(\xi_1) \rangle_r = \\ &= \mathbf{g}(\mathbf{x}) + \frac{\mathbf{K}(\mathbf{x}, \xi_1)}{p_1(\xi_1)} \cdot \left[ \mathbf{g}(\xi_1) + \frac{\mathbf{K}(\xi_1, \xi_2)}{p_2(\xi_2)} \cdot \langle \mathbf{f}(\xi_2) \rangle_r \right] \\ &= \mathbf{g}(\mathbf{x}) + \frac{\mathbf{K}(\mathbf{x}, \xi_1)}{p_1(\xi_1)} \mathbf{g}(\xi_1) + \frac{\mathbf{K}(\mathbf{x}, \xi_1)}{p_1(\xi_1)} \frac{\mathbf{K}(\xi_1, \xi_2)}{p_2(\xi_2)} \mathbf{g}(\xi_2) + \dots\end{aligned}$$



# Rekurzivní Monte Carlo odhad

$$\langle \mathbf{f}(\mathbf{x}) \rangle_r = \sum_{i=0}^{\infty} \left[ \prod_{j=1}^i \frac{\mathbf{K}(\xi_{j-1}, \xi_j)}{\mathbf{p}_j(\xi_j)} \right] \mathbf{g}(\xi_i), \quad \xi_0 = \mathbf{x}$$

$\{\xi_1, \xi_2, \xi_3, \dots\}$  se nazývá **Markovovský řetězec**,  
jestliže pravděpodobnost  $\mathbf{p}_i(\mathbf{x})$  závisí pouze na  $\xi_{i-1}$

Úspornější funkcionální zápis:  $\mathbf{f} = \mathbf{g} + \mathbf{T}\mathbf{f}$

**Řešení** (Neumannova řada):  $\mathbf{f} = \mathbf{g} + \mathbf{T}\mathbf{g} + \mathbf{T}^2\mathbf{g} + \dots$



# Ruská ruleta

- ♦ při odhadu **nekonečné Neumannovy řady** se může spočítat jen konečný částečný součet
  - pevně daná délka posloupnosti zavádí do odhadu **systematickou chybu**
- ➡ vhodnější je metoda náhodného ukončení výpočtu: tzv. **ruská ruleta**
  - odhad zůstává nestranný
- teoreticky se dá tento postup aplikovat i na výpočet jednotlivého integrálu



# Ruská ruleta pro jeden integrál

Transformace integrálu:

$$I = \int_0^1 f(x) dx = \int_0^P \frac{1}{P} f\left(\frac{t}{P}\right) dt \quad 0 < P \leq 1$$

Nestranný odhad s jedním náhodným vzorkem:

$$\langle I \rangle_{\text{Russ}} = \begin{cases} \frac{1}{P} f\left(\frac{\xi}{P}\right) & \text{pro } \xi < P \\ 0 & \text{jinak} \end{cases}$$

---

# Ruská ruleta pro integrální rovnice

$$\langle \mathbf{f}(\mathbf{x}) \rangle_{\text{Russ},r} = \sum_{i=0}^k \left[ \prod_{j=1}^i \frac{\mathbf{K}(\xi_{j-1}, \xi_j)}{\mathbf{P}_j \cdot \mathbf{p}_j(\xi_j)} \right] \mathbf{g}(\xi_i), \quad \xi_0 = \mathbf{x}$$

$\{\xi_1, \xi_2, \dots, \xi_k\}$  je **konečná** náhodná procházka, protože odhad  $\langle \mathbf{f}(\xi_k) \rangle = 0$ .

Každý vzorek  $\xi_i$  je vybírán s **pravděpodobností**  $\mathbf{P}_i$  a s hustotou (pdf)  $\mathbf{p}_i(\mathbf{x})$ .

Pokud náhodná proměnná  $\tau_{i+1} > \mathbf{P}_{i+1}$ , celý proces se zastaví; jinak se vygeneruje  $\xi_{i+1}$  (a přidá se další člen).



# Volba pravděpodobností

Ve fyzikálních aplikacích je často:  $\int_0^1 \mathbf{K}(\mathbf{x}, \mathbf{y}) \, d\mathbf{y} < 1$

Tedy lze jádro  $\mathbf{K}$  použít ke konstrukci tzv.  
**subkritického rozdělení pravděpodobnosti:**

$$P_i = \int_0^1 \mathbf{K}(\xi_{i-1}, \mathbf{y}) \, d\mathbf{y}, \quad p_i(\mathbf{x}) = \frac{\mathbf{K}(\xi_{i-1}, \mathbf{x})}{P_i}$$

Odhad pak bude mít tvar:

$$\langle \mathbf{f}(\mathbf{x}) \rangle_{\text{subcrit}} = \sum_{i=1}^k g(\xi_i)$$





# Odhad příští události

Předchozí odhad mívá **velký rozptyl** (málo sčítanců je nenulových). Lepší výsledky dává metoda odhadující člen  **$g(x)$**  o jeden stupeň přesněji:

$$f(x) = g(x) + h(x)$$

$$h(x) = \int_0^1 K(x, y) \cdot f(y) dy =$$

$$= \underbrace{\int_0^1 K(x, y) \cdot g(y) dy}_{\text{red line}} + \underbrace{\int_0^1 K(x, y) \cdot h(y) dy}_{\text{green line}}$$



# Odhad příští události

- ♦ **první integrál** se odhaduje za pomoci pravděpodobnosti s hustotou podobnou funkci  $\mathbf{g}(\mathbf{x})$ 
  - náhodná proměnná  $\zeta_i$  s hustotou  $\mathbf{p}_i(\mathbf{x})$
- ♦ **druhý integrál** se odhaduje pomocí subkritické hustoty pravděpodobnosti jádra  $\mathbf{K}$ 
  - náhodná proměnná  $\xi_i$  s hustotou  $\mathbf{K}(\xi_{i-1}, \mathbf{x})/P_i$

$$\langle \mathbf{h}(\mathbf{x}) \rangle_{\text{nextev}} = \frac{\mathbf{K}(\mathbf{x}, \zeta_1) \mathbf{g}(\zeta_1)}{\mathbf{p}_1(\zeta_1)} + \langle \mathbf{h}(\xi_1) \rangle_{\text{nextev}}$$



# Odhad příští události

Odhad funkce  $h$ :

$$\langle h(\mathbf{x}) \rangle_{\text{nextev}} = \sum_{i=1}^k \frac{K(\xi_{i-1}, \zeta_i) g(\zeta_i)}{p_i(\zeta_i)}$$

Odhad integrální rovnice:

$$\langle f(\mathbf{x}) \rangle_{\text{nextev}} = g(\mathbf{x}) + \sum_{i=1}^k \frac{K(\xi_{i-1}, \zeta_i) g(\zeta_i)}{p_i(\zeta_i)}$$

# Konec



## Další informace:

- **E. Lafortune: *Mathematical Models and Monte Carlo Algorithms for Physically Based Rendering*, PhD thesis, KU Leuven, 29-63**
- **M. Kalos, P. Whitlock: *Monte Carlo Methods*, John Wiley & Sons, 1986, 89-116**
- **A. Glassner: *Principles of Digital Image Synthesis*, Morgan Kaufmann, 1995, 840-864**